Langage d'assemblage : Syntaxe, directives

Ensimag 1A Apprentissage

Matthieu Moy

Matthieu.Moy@imag.fr

mai 2012

Sommaire

Exemples

- Instructions :

```
iter:  cmpw $0,%ax   /* compare word */
       je   fin      /* jump if equal */
       shrw $1,%ax   /* shift right word */
       jnc  suite    /* jump if no carry */
       add  %dx,%ax  /* add */
suite: shlw $1,%dx   /* shift left word */
       jmp  iter     /* jump inconditionnel */
fin:
```

- Données :

```
toto: .byte 0xff /* Un octet, de valeur 0xFF */
lulu: .int   $5000, suite /* Deux entiers sur 32 bits,
                             de valeur 5000, puis l'adresse
                             de l'etiquette suite */
```


Modèle mémoire (assembleur gnu)

Les directives : .text, .data, .section

```
       .section .data
un:    .int 1
...      ...
       .section .bss
       .lcomm tab,10
tab1: skip 10
---
       .text
main: pushl %ebp
```

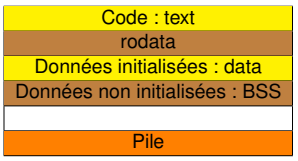

Programme source

- Ensemble de sections
- data (`.rodata`, `.bss`) pour les données
- text (`.text`) pour les instructions
- Chaque section est une suite de lignes :
  - Pour les instructions :
    [*etiquette* :] *code op opérandes*
    Exemple : `addl $42, %eax`
  - Pour les données :
    [*etiquette* :] *def de donnée suite de valeurs*
    Exemple : `x: .int 42`
- des commentaires
- des directives d'assemblage

Représentation symbolique des instructions

- Code de l'opération
  - La dernière lettre correspond à la longueur des opérandes
  - Exemple : shrw, subl, movb
- Représentation symbolique des opérandes :
  - Registre. Ex : %eax
  - Adresse en mémoire, dénotée par un mode d'adressage Ex : 4(%ecx)
  - Valeur immédiate Ex : $0x45ab

⚠ les types d'opérandes valides dépendent des instructions

Les commentaires

- Définition : il s'agit de textes non interprétés par l'assembleur et qui sont fournis par le programmeur pour augmenter la lisibilité de son programme.
- Comme en C (avec des fichiers *.S, S majuscule) :
  - soit sur une ligne tout ce qui suit // jusqu'à la fin de ligne
  - soit ce qui est entre les deux couples de caractères /* et */
- Alternative : # jusqu'à la fin de la ligne

Les étiquettes

- Une étiquette (identificateur suivi de « : ») sert à désigner l'adresse d'un emplacement de mémoire
- On peut l'utiliser dans un champ opérande
- Exemple : `toto: movw %eax,lulu`

Les étiquettes

- Déclaration d'étiquette :
  `toto: <quelquechose>`
  - Ne génère pas de code
  - Définie toto comme l'adresse de *<quelquechose>*
- Utilisation d'étiquette :
  `movl toto, %eax`
  - L'étiquette est remplacée par sa valeur (i.e. l'adresse de l'endroit où elle est définie)

Directives d'assemblage

- Directives d'assemblage : commandes fournies par l'assembleur qui ne correspondent à aucune instruction du processeur.
- Elles permettent entre autres :
  - La définition de données.
  - La définition de constantes ou de symboles.
  - Les sections (`.text` et `.data`)

Définition de données initialisées

- [*etiquette* :] *.type de donnée val1*, *val2*, *val*, ...
- *type de donnée* = `byte` | `hword` | `long` | `quad` | `asciz`
- Exemple :

```
.data
xi: .long 0xaabbccdd, xi, -4500
xb: .byte 0x3f, 35, 'c'
message: .asciz  "Hello World"
```

Définition de données non-initialisées

- Section `.bss` dédié aux données non-initialisées
  - Ne prends pas de place dans le fichier binaire
  - Alloué (et initialisé à 0) au chargement
- Directives d'assemblages :
  - `.lcomm` nom, taille (pratique pour les tableaux)
  - [etiquette :] `.skip` taille (à utiliser dans la section `.bss`)

Exemple

```
$ gcc exemple.S -m32 -Wa,-a
   2 0000 DDCCBBAA      xi: .long 0xaabbccdd, xi, -4500
   2      00000000
   2      6CEEFFFF
   3 000c 3F2363        xb: .byte 0x3f, 35, 'c'
   4 000f 48656C6C      message: .asciz  "Hello World"
   4      6F20576F
   4      726C6400
   5                            .lcomm tab1, 10
   6                            .lcomm tab2, 10
   7                    .text
   8                            .globl main
   9 0000 55            main:   pushl %ebp
DEFINED SYMBOLS
           exemple.S:2      .data:0000000000000000 xi
           exemple.S:3      .data:000000000000000c xb
           exemple.S:4      .data:000000000000000f message
           exemple.S:5      .bss:0000000000000000 tab1
           exemple.S:6      .bss:0000000000000010 tab2
           exemple.S:9      .text:0000000000000000 main
```

Définition de constantes

- *symbole* = *expression*
- Comme le `#define` du langage C
- associe de façon définitive la valeur d'*expression* au symbole défini par le champ *symbole*.
- Remplacement syntaxique et statique : on pourrait le faire avec « rechercher/remplacer » dans un éditeur de texte !
- Syntaxes alternatives :
  - `.set` *symbole*, *expression*
  - `.equ` *symbole*, *expression*
  - `#define` *symbole expression*

Exportation de symbole

- Motivation : pouvoir définir (resp. utiliser) dans un module d'assemblage du code et des données utilisables (resp. définis) dans un autre module d'assemblage produit par un compilateur ou par un programmeur.
- Directive `.globl` (ou `.global`)
  - `.globl` *étiquette1*, ...
    ⇒ rendre les étiquettes *étiquette1*, ... (définies dans le module courant) visible depuis l'extérieur du module
  - Toute étiquette référencée dans le module courant sans y être définie est considérée comme externe, donc définie dans un autre module d'assemblage (pas d'erreur à l'assemblage).
  - L'édition de liens (plus tard) fait le lien entre symboles indéfinis et symboles globaux des autres modules.
  - Exemple :

```
.globl main // chaque programme comporte un
            // ''main'' appele par le systeme
```

Introduction aux modes d'adressages

- Exemples
  - `movl $42, %eax` (`$42` = valeur immédiate, `%eax` = registre)
  - `movl toto, %ebx` (`toto` = valeur située à l'adresse `toto`)
  - ~~`movl 2*(toto + %ebx), %eax`~~
- Les opérandes des instructions ne peuvent pas être des expressions quelconques.
- Expressions autorisées comme opérandes = mode d'adressages

Modes d'adressages principaux du Pentium

cf. EnsiWiki « LdB Modes d'adressages » :
`http://ensiwiki.ensimag.fr/index.php/LdB_Modes_d%27adressages`