Édition de lien, fichiers ELF

Ensimag 1A Apprentissage, Mai 2010

Exemple

- Un programme, deux fichiers :

ppal.s

```
        .text
        .global main
main:
        push %ebp
        movl %esp, %ebp

        call dire_bonjour

        leave
        ret
```

bonjour.s

```
        .data
bonjour: .string "bonjour\n"
        .text
        .global dire_bonjour
dire_bonjour:
        push %ebp
        movl %esp, %ebp

        pushl $bonjour
        call printf
        addl $4, %esp

        leave
        ret
```


Génération d'un exécutable

- Assemblage :
  - `gcc -c ppal.s -o ppal.o` # crée ppal.o
  - `gcc -c bonjour.s -o bonjour.o` # crée bonjour.o
  - À ce stade, **`ppal.o`** ne connait pas encore l'adresse de la fonction “dire_bonjour”
- Édition de liens :
  - `gcc ppal.o bonjour.o -o mon_programme`

Contenu des fichiers *.o

- La commande “nm” permet de connaitre les symboles utilisés et définis par un binaire :

```
$ nm ppal.o bonjour.o
bonjour.o:
00000000 d bonjour
00000000 T dire_bonjour
         U printf
ppal.o:
         U dire_bonjour
00000000 T main
```

“d” comme “data”
“T” comme “text”
“U” comme “undefined”

Définition

Liaison = toute opération qui établit tout ou partie de la chaîne d’accès qui permet de passer du nom d’un objet informatique à sa représentation physique

Caractéristiques de la liaison (1)

Liaison d’un objet lors de la traduction du programme

- Liaison partielle
  - Compilation : les identificateurs sont remplacés par des adresses relatives à l’origine de blocs bien identifiés (section data, text par exemple)
    - *Ex. : bonjour remplacé par @.data+0x00*
    - Le programme produit n’est plus directement exécutable et doit être traité lors d’une phase d’édition de liens/chargement
  - Edition de liens : cette phase a pour but d’établir la liaison des références externes (références à des objets de bibliothèques de programmes ou à des objets définis dans des modules compilés séparément)

Etape de la vie d’un programme programme unique

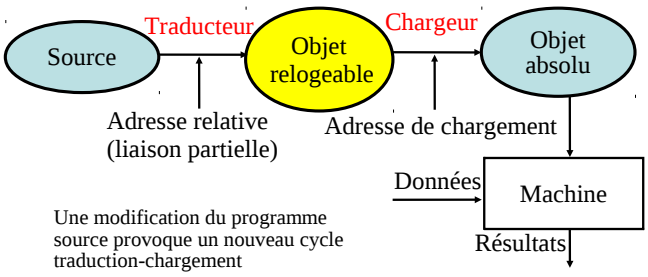

Une modification du programme source provoque un nouveau cycle traduction-chargement

Etape de la vie d’un programme programme composé

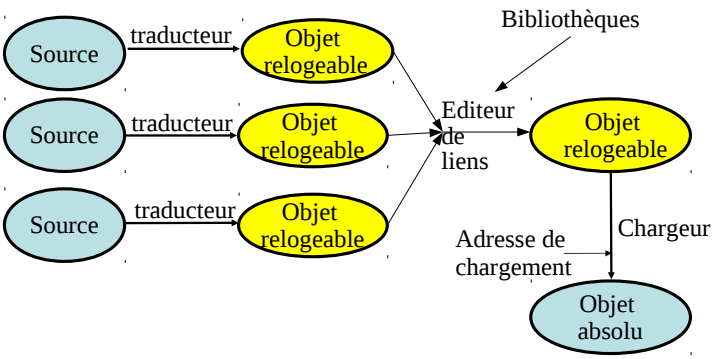

Table de relocation, table des symboles

- Table des symboles
  - Liste des adresses (relatives) des symboles dans leur section
  - Rq : si plusieurs sections de même type, elles sont fusionnées au préalable
- Table de relocation/relogement
  - Liste des trous dans le code à remplir (en utilisant la table de symboles)

Structures de données

- Table des symboles

Section	@relative	nom symbole
	undef	

- Table de relogement (adresse des modifications à faire dans le code)

Adresse du trou	Section symbole	Nom symbole

Exemple

- Code :

```
1                       .section .data
2 0000 03000000 i:      .int 3
3 0004 FF       j:      .byte 0xff
4                       .section .text
5                       .global main
6 0000 B8000000 main:   movl $i,%eax
6      00
7 0005 3A050400         cmpb j,%al
7      0000
8 000b 3D000000         cmpl $main,%eax
8      00
9 0010 C3               ret
```

- Table des symboles :

data	0x00	i
data	0x04	j
text	0x00	main

- Table de reloc :

0x01	text	.data (-> i)
0x07	text	.data (-> j)
0x0c	text	main

Exemple (2)

- Table de relogement :

AD		S
0x01	text	.data (-> i)
0x07	text	.data (-> j)
0x0c	text	main

- Chaque ligne = 1 “trou” dans le fichier relogeable
- Relogement :
  - emplacement(AD) := emplacement(AD) + adresse_finale_de(S)
- En fait, plusieurs types de relogements
  - Cf. documentation du projet.

Structure de donnée (prg composé)

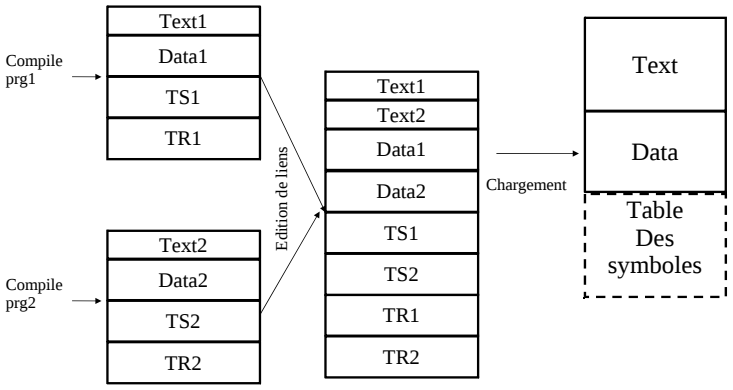

Exemple

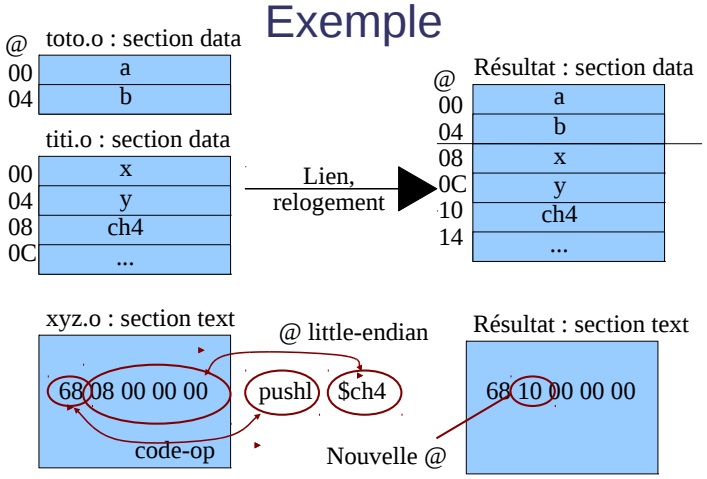

Fonctions d’un chargeur

- Transformer «l’objet relogeable» en «objet absolu»

```
    .section data
adtab: .long  tab    # tab est relative à la section bss
adsom: .long  som    # som est relative à la section text
x:     .long  3
    .section bss
…
       .lcomm tab, 10
…
    .section text
…
som:   enter  $10,0
       pushl  $x     # x est relatif à la section data
…
```

tab, som, x sont dites des adresses translatables

- Si c’est un «load and go» on doit déterminer l’adresse absolue qui doit recevoir le contrôle

Le format ELF : motivations

- Types de fichiers utilisés dans la chaine de compilation :
  - Source de haut niveau (C, ...)
  - Assembleur (fichier.s)
  - Objet (fichier.o)
  - Bibliothèques partagées (fichier.so)
  - Executables
- Besoins similaires pour .o, .so et executables :
  - Code compilé
  - Différentes sections (.data, .text, ...)
  - Tables (de symbole, de relogement)

Le format ELF : principe

- ELF : Executable and Linkable Format
- Format commun aux .o, .so et exécutables
- Principe de ELF :
  - Stoquer dans le même fichier toutes les informations (sections, tables de symboles, ...)
  - Séquentialisation (1 fichier = 1 suite d'octets)
- Concretement :
  - Un en-tête qui donne les adresses des sections suivantes
  - Les sections, les unes après les autres

Le format ELF : Informations supplémentaires

- Motivation :
  - permettre la liaison dynamique et notamment faciliter la gestion à l'exécution du langage C++
- Remplacement du Common Object File Format (COFF, qui était le format d'Unix système V)
- Format actuel d'Unix système V, Linux, et de nombreuses variantes d'Unix BSD (mais pas Mac OS X qui utilise Mach-O)
- Un ficher ELF peut être relogeable, exécutable ou partageable
  - Relogeable => doit être traité par l'éditeur de liens
  - Exécutable => a été relogé, et a tous ses symboles résolus sauf peut être les références aux bibliothèques partagées qui sont résolues à l'exécution
  - Partageable => une bibliothèque partagée

Le format ELF (2)

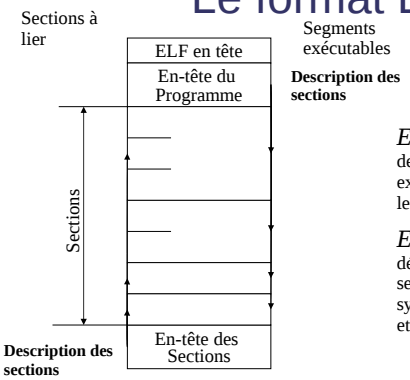

En-tête section : c'est la table des descripteurs des sections. Cette table est exploitée par l'éditeur de liens. Existe dans les fichiers relogeables et partageables

En-tête du programme : cette table décrit le programme comme un ensemble de segments et est exploitée par le chargeur du système. Existe dans les fichiers exécutables et partageables

Le format ELF (3)

- L'entête d'un fichier `ELF` (type C : `struct Elf32_Ehdr`) donne des informations sur le format et le nombre de sections du fichier
- Il possède aussi un "pointeur" vers la table des entêtes de sections : `e_shoff`
  ⇝ *"pointeur" = valeur indiquant le déplacement par rapport au début du fichier*
- Entête de section (type C : `struct Elf32_Shdr`) : infos sur la taille de la section, son emplacement dans le fichier, son type, ...
- Types de sections : `.text`, `.data`, `.bss`, table des symboles, tables des chaînes (noms de sections, noms de symboles), tables de relocations, ...

Le format ELF (4)

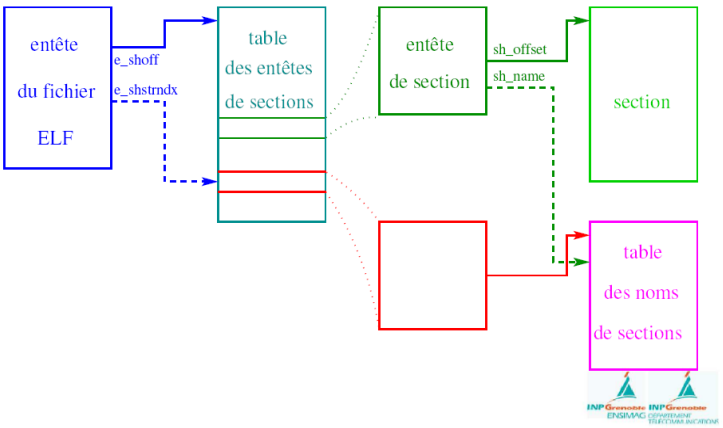

Le format ELF : table des chaines, tables des symboles

- Table des chaines : chaines (noms de symboles, ...) concaténées (séparateur : '\0')

'\0'	v	a	r	'\0'	m	a	i	n	'\0'	f	i	n	i	f	'\0'
0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15

- Table des symboles : liste des symboles définis/indéfinis :
  - Nom (indice dans table des chaines)
  - Numéro (utilisé dans la table de relocation)
  - Section (indice dans la table des sections)
  - Adresse relative au début de section
  - ...

Format ELF : l'en-tête du fichier

```
char magic[4];     // tableau initialisé avec \177ELF
char class;        // taille d'une adresse 1 pour 32 bit et 2  pour 64 bit
char byteorder;    // 1 little endian, 2 big endian
char hversion;     // version de l'en-tête toujour 1.
char pad[9];
short filetype; // 1 relogeable, 2 exécutable, 3 partageable, 4 image mém.
short archtype; // 2 Sparc, 3 x86, 4 68K, …
int fversion;   // toujours 1
int entry;      // point d'entrée si c'est un exécutable
int phdrpos, shdrpos; // position dans le fichier des en-têtes programme et segment ou 0
int flags;         // fanion propre à certaine architecture, en général 0
short hdrsize;     // taille de cet en-tête
short phdrent;// taille d'une entrée de la table des en-têtes programme
short phdrcnt;// nombre d'entrées dans la table précédente ou 0
short shdrent;// taille d'une entrée dans la table des en-tête de section
short shdrcnt;// nombre d'entrées dans la table précédente ou 0
short strsec; // numéro de la section qui contient les noms de sections.
```


Format ELF : en-tête de section

```
int sh_name;  /* index dans la table des chaînes */
int sh_type;  /* type de section */
int sh_flags; /* 3 bits utilisés :
                 ALLOC, WRITE, EXEINST */
int sh_addr;  /* adresse de base en mémoire
                 si chargeable ou 0 */
int sh_offset;    /* déplacement dans le fichier
                     du début de la section */
int sh_size;  /* taille en octets */
int sh_info;  /* information spécifique à la section */
int sh_align; /* granularité de l'alignement
                 si la section est déplacée */
int sh_entsize/* taille d'une entrée
                 si la section est un tableau */
```

Format ELF : types des sections 1

- Le champ sh_type de section inclut les types suivant :
  - PROGBIT: la section peut contenir du code des données et des information de mise au point.
  - NOBIT : identique à PROGBIT mais aucune mémoire n'est allouée dans le fichier. Est utilisé pour la section bss.
  - SYMTAB et DYNSYM : la section contient une table des symboles soit pour la liaison statique soit pour la liaison dynamique.
  - STRTAB : la liaison contient les noms des symboles qui sont en général spécialisé (nom de section, symbole pour l'édition de lien dynamique,…).
  - REL et RELA : la section contient des informations de relogement. REL provoque l'addition de la valeur de relogement à la valeur de base stockée dans le code ou les données, RELA inclut la valeur de relogement dans l'entrée
  - DYNAMIC and HASH contient des informations pour l'éditeur de liens dynamique

Format ELF : types des sections 2

- Un fichier relogeable exécutable contient une douzaine de section :
  - .text de type PROGBIT avec les attribut ALLOC+EXECINSTR
  - .data de type PROGBIT avec les attribut ALLOC+WRITE
  - .rodata de type PROGBIT avec l'attribut ALLOC
  - .bss de type NOBIT avec les attribut ALLOC+WRITE
  - .rel.text, .rel.data, et .rel.rodata chacune est de type REL ou RELA et contient les informations permettant de reloger le code ou les données.
  - .init et .fini chacune de type PROGBIT avec les attribut ALLOC+EXECINSTR
  - .symtab et .dynsym respectivement de type SYMTAB et DYNSYM. La section .dynsym a l'attribut ALLOC positionné.
  - .strtab et .dynstr toutes les deux de type STRTAB. .dynstr a l'attribut ALLOC positionné.
  - .got et .plt ces deux sections sont utilisés pour la liaison dynamique
  - .debug, .line (association ligne source, code), .comment

Format ELF : table des symboles

```
int  name;    /* position du nom dans la table
                 des chaînes */
int value;    /* valeur du symbole, relative à la
                 section dans le fichier relogeable */
int size;     /* taille de l'objet ou de la fonction */
char type;    /* donnée, fonction, section, ou
                 spécial (nom du fichier source) */
char bind;    /* symbole local, global ou faible */
char other;      /* pas utilisé */
short sect;      /* numéro de la section,
                 ABS, COMMON, UNDEF */
```


Format ELF : en-tête programme

```
int  type;    /* code, ou données chargeables, info pour
                 l'édition de liens dyna. */
int offset;   /* déplacement dans le fichier du segment */
int virtaddr; /* adresse de chargement du segment */
int physaddr; /* pas utilisé */
int filesize; /* taille du segment dans le fichier */
int memsize;  /* taille du segment en mémoire (bss…) */
int flags;    /* Read, Write, Execute */
int align     /* alignement requis */
```